

Sau bài thực hành này, sinh viên có thể

- Viết được chương trình sử dụng các hàm Actions
- Viết được chương trình xử lý đối tượng Key/Value trong RDD của Spark

1. THỰC HÀNH CÁC HÀM TRONG ACTIONS

1.1. Đếm số phần tử trong RDD

```
import random

from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

numberRDD = spark.sparkContext.parallelize([1,2,3,4,5,6,7,8,9,10], 2)
print(numberRDD.count())
```

1.2. Cho biết phần tử đầu tiên của RDD

```
import random

from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

numberRDD = spark.sparkContext.parallelize([1,2,3,4,5,6,7,8,9,10], 2)
print(numberRDD.first())
```

1.3. Cho biết n phần tử đầu tiên trong RDD

```
import random

from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

numberRDD = spark.sparkContext.parallelize([1,2,3,4,5,6,7,8,9,10], 2)
print(numberRDD.take(5))
```

1.4. Tính tổng các giá trị trong RDD

```
import random

from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

numberRDD = spark.sparkContext.parallelize([1,2,3,4,5,6,7,8,9,10], 2)

def add1(a, b):
    print(f'v1:{a}; v2:{b}')
    return a + b

rdd = numberRDD.reduce(add1)
print(rdd)
```

1.5. Lấy tập mẫu từ RDD

```
import random

from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

numberRDD = spark.sparkContext.parallelize([1,2,3,4,5,6,7,8,9,10], 2)

rdd = numberRDD.takeSample(True, 5)
print(rdd)
```

1.6. Lấy mẫu có thứ tự trong RDD

```
import random

from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

numberRDD = spark.sparkContext.parallelize([1,2,3,4,5,6,7,8,9,10], 2)

rdd = numberRDD.takeOrdered(5)
rdd1 = numberRDD.takeOrdered(5, lambda x: -x)
print(rdd)
print(rdd1)
```

1.7. Lấy danh sách n phần tử có giá trị lớn nhất trong RDD

```
import random

from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

numberRDD = spark.sparkContext.parallelize([1,2,3,4,5,6,7,8,9,10], 2)

rdd = numberRDD.top(5)
print(rdd)
```

1.8. Lưu RDD vào file

```
import random

from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

numberRDD = spark.sparkContext.parallelize([1,2,3,4,5,6,7,8,9,10], 2)
numberRDD.saveAsTextFile('D:/number')
```


2. THỰC HÀNH ĐỐI TƯỢNG KEY/VALUE TRONG RDD

2.1. Tạo đối tượng Key/Value cơ bản

```
import random

from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

data = ((1, "Truong"), (2, "Dai"), (3, "Hoc"),
        (4, "Van"), (5, "Lang"))
rdd = spark.sparkContext.parallelize(data, 2)
print(rdd.collect())
```

2.2. Nhóm giá trị theo key trong RDD

```
import random

from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

data = ((1, "Truong"), (2, "Dai"), (2, "Hoc"),
        (3, "Van"), (3, "Lang"))
rdd = spark.sparkContext.parallelize(data, 2)
rdd2 = rdd.groupByKey().mapValues(list)
print(rdd2.collect())
```

2.3. Nhóm giá trị cùng key và thực hiện tính toán trên RDD

```
import random

from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

data = [('Project', 1),
        ('Gutenberg', 1),
        ('Adventures', 1),
        ('Adventures', 1),
        ('Gutenberg', 1),
        ('Project', 1)]

rdd = spark.sparkContext.parallelize(data, 2)
rdd2 = rdd.reduceByKey(lambda a, b: a + b)
print(rdd2.collect())
```

2.4. Sắp xếp RDD theo Key

```
import random
from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

data = [('Project', 1),
        ('Gutenberg', 1),
        ('Adventures', 1),
        ('Adventures', 1),
        ('Gutenberg', 1),
        ('Project', 1)]
rdd = spark.sparkContext.parallelize(data, 2)
rdd2 = rdd.reduceByKey(lambda a, b: a + b)
print(rdd2.collect())
rdd3 = rdd2.sortByKey()
print(rdd3.collect())
```

2.5. Kết hợp nhiều tập hợp Key-Value trong RDD

```
import random
from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

data = [(1, 8.5), (2, 7.2), (3, 9.3)]
data1 = [(1, "A"), (2, "B"), (3, "C")]
rdd = spark.sparkContext.parallelize(data, 2)
rdd1 = spark.sparkContext.parallelize(data1, 2)
rdd2 = rdd.join(rdd1)
print(rdd2.collect())
```

2.6. Đếm số lần một key xuất hiện trong RDD

```
import random
from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

data = [('Project', 1),
        ('Gutenberg', 1),
        ('Adventures', 1),
        ('Adventures', 1),
        ('Project', 1),
        ('Project', 1)]
rdd = spark.sparkContext.parallelize(data, 2)
rdd2 = rdd.countByKey()
print(rdd2)
```


2.7. Thu thập các dòng dữ liệu RDD theo phân hoạch và trả về một dictionary

```
import random
from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

data = [('Project', 1),
        ('Gutenberg', 1),
        ('Adventures', 1),
        ('Adventures', 1),
        ('Project', 1),
        ('Project', 1)]
rdd = spark.sparkContext.parallelize(data, 2)
rdd2 = rdd.collectAsMap()
print(rdd2)
```

2.8. Tìm kiếm theo key trong một RDD

```
import random
from pyspark.sql import SparkSession
import findspark
findspark.init()

spark = SparkSession.builder\
    .master('local[1]')\
    .appName('bai_thuc_hanh_2.com')\
    .getOrCreate()

data = [('Project', 1),
        ('Gutenberg', 1),
        ('Adventures', 1),
        ('Adventures', 1),
        ('Project', 1),
        ('Project', 1)]
rdd = spark.sparkContext.parallelize(data, 2)
rdd2 = rdd.lookup('Project')
print(rdd2)
```

3. BÀI TẬP

Sử dụng tập tin movies.tsv và movie-rating.tsv do giảng viên cung cấp

- 3.1. Tính số phim sản xuất theo từng năm. Kết quả đầu ra gồm 2 cột: year và count. Sắp xếp giá trị cột count giảm dần.
- 3.2. Tính số phim mà mỗi diễn viên có tham gia. Kết quả đầu ra gồm 2 cột: actor và count. Sắp xếp giá trị cột count giảm dần.
- 3.3. Tính phim có rating cao nhất theo từng năm. Kết quả đầu ra gồm 4 cột year, movie_title, rating, và danh sách các diễn viên tham gia phim đó.
- 3.4. Cho biết danh sách diễn viên
- 3.5. Cho biết cặp diễn viên làm việc chung dự án phim với nhau nhiều nhất. Kết quả đầu ra gồm actor1, actor2, và count. Sắp xếp cột count giảm dần.
- 3.6. Tìm tất cả các movie do diễn viên Angelina Jolie đóng.
- 3.7. Tìm tất cả các năm mà movie nhận rating [4 – 5] và sắp xếp tăng dần.
- 3.8. Tìm tất cả các movie không được đánh giá hoặc < 1.
- 3.9. Liệt kê cột tên movie, và 'rating spread'. Trong đó, cột 'rating spread' cho biết rating thấp nhất và cao nhất của movie. Sắp xếp 'rating spread' từ cao xuống thấp.
- 3.10. Tìm khoảng cách giữa rating trung bình của những movie được sản xuất trước 2000 và sau 2000. (Tính trung bình rating từng movie, sau đó tính trung bình của những movie trước 2000, rồi mới tính movie sau 2000).
- 3.11. Tìm những movie mà diễn viên “Carley, Kurt” không tham gia sau năm 2000.
- 3.12. Tìm cặp diễn viên cùng tham gia dự án movie trong 2005 – 2010 và cho biết diễn viên nào thành công hơn (có rating những movie tham gia lớn hơn).
- 3.13. Tìm diễn viên thành công nhất (Có rating trung bình cao nhất nhưng đóng ít phim nhất). Kết quả trả về 3 cột actor, number_of_movies, avg_rating.
- 3.14. Cho biết danh sách diễn viên mỗi movie, trong đó diễn viên nào nổi tiếng nhất (Có rating trung bình cao nhất). Kết quả trả về 3 cột movie, actors, best_actor.
- 3.15. Với mỗi diễn viên, cho biết rating trung bình, và số phim đóng theo từng năm. Cho biết năm nào là năm thành công nhất của diễn viên đó (đóng nhiều phim và rating cao).